

Análisis Topológico de Datos Moleculares mediante el Algoritmo MAPPER

Nuria Arroyo Bustamante

15 de abril de 2026

1. Introducción

El objetivo de este trabajo es analizar la estructura topológica de un conjunto de moléculas utilizando el algoritmo MAPPER. A diferencia de métodos tradicionales de clustering, el enfoque topológico permite capturar no solo agrupamientos locales, sino también la organización global del espacio de datos, incluyendo conexiones, regiones intermedias y posibles transiciones entre familias moleculares.

Para ello se construyó un pipeline computacional que parte de representaciones moleculares en formato SMILES, las transforma en grafos químicos, calcula una medida de similitud estructural mediante el esquema de Weisfeiler–Lehman y, a partir de ella, genera una matriz de distancias. Sobre ese espacio métrico se hace una visualización previa con UMAP y posteriormente se construye el grafo MAPPER usando una función filtro basada en excentricidad.

2. Descripción de los datos

El conjunto de datos proviene del archivo `NPASSv2.0_structureInfo.txt`, que contiene compuestos moleculares descritos mediante diferentes identificadores químicos. En el pipeline se cargan todos los registros disponibles y posteriormente se eliminan las observaciones con valores faltantes en la columna `SMILES`. Para hacer manejable el cálculo de la matriz de similitud, se selecciona una muestra aleatoria de 1000 moléculas con semilla fija (`random_state=42`).

Cada observación corresponde a una molécula individual. Aunque el archivo original contiene varios campos descriptivos, el análisis topológico se apoya principalmente en la estructura química codificada por los SMILES, ya que a partir de ella se construyen los grafos moleculares.

Se consideran las siguientes variables:

- **SMILES**: representación en texto plano de la estructura molecular; es la variable principal del pipeline.
- **Graph**: variable derivada construida en el preprocesamiento, donde cada molécula se representa como un grafo no dirigido.

Se descartan:

- Registros con **SMILES** faltante, porque no permiten reconstruir la estructura molecular.
- Las demás columnas del archivo original, ya que no intervienen en la definición de la similitud estructural utilizada en este análisis.

3. Construcción del espacio métrico

3.1. Representación molecular

Cada molécula se representa como un grafo, donde los nodos corresponden a átomos y las aristas a enlaces químicos. Esta construcción se hace con RDKit a partir de la cadena SMILES. En cada nodo se conserva información básica del átomo, en particular su número atómico, su símbolo químico y si pertenece o no a un sistema aromático. En cada arista se registra el tipo de enlace.

3.2. Medida de similitud

La similitud estructural entre moléculas se define mediante una versión del esquema de Weisfeiler–Lehman (WL) aplicada a grafos moleculares. Primero se asigna a cada nodo una etiqueta inicial basada en el número atómico y la aromaticidad. Luego, durante dos iteraciones ($h = 2$), cada etiqueta se actualiza agregando la información de las etiquetas vecinas junto con el tipo de enlace correspondiente.

Las etiquetas obtenidas a lo largo de todos los niveles se acumulan en un vector tipo bolsa de características para cada molécula. Finalmente, la similitud entre dos vectores WL se calcula mediante un coeficiente de Tanimoto para conteos, lo que produce una medida de similitud estructural entre pares de moléculas.

3.3. Definición de distancia

A partir de la similitud, se define la distancia como:

$$d(i, j) = 1 - s(i, j)$$

En el pipeline se calcula primero la matriz de similitud WL y después se transforma en una matriz de distancias mediante la expresión anterior. Así, se obtiene una matriz cuadrada de tamaño 1000×1000 que dota al subconjunto analizado de una estructura de espacio métrico finito.

Esta construcción permite interpretar el conjunto de datos como una nube de puntos en un espacio métrico finito, lo cual es el punto de partida para la aplicación de técnicas de análisis topológico de datos.

4. Visualización previa de los datos

El conjunto de datos se interpreta como una nube de puntos en un espacio métrico definido por la matriz de distancias precomputada. Como esta representación no vive naturalmente en un espacio euclidiano de baja dimensión, se utilizó UMAP con métrica `precomputed` para obtener una proyección bidimensional.

Esta visualización no sustituye el análisis topológico, pero permite inspeccionar de forma preliminar la distribución global de las moléculas y detectar posibles regiones densas o transiciones entre grupos.

Se conserva:

- La geometría inducida por la matriz de distancias WL.
- La proximidad relativa entre moléculas estructuralmente similares.

Se descarta:

- Parte del detalle fino de alta dimensión al proyectar los datos a dos dimensiones.
- La interpretación directa de coordenadas químicas originales, ya que la visualización depende solo de las distancias estructurales.

5. Función filtro

5.1. Definición

Se utiliza la excentricidad media como función filtro, definida como:

$$f(x_i) = \frac{1}{n} \sum_{j=1}^n d(x_i, x_j)$$

5.2. Interpretación

Esta función mide qué tan lejos se encuentra, en promedio, una molécula con respecto al resto del conjunto. Valores bajos corresponden a moléculas más centrales dentro del espacio químico definido por la distancia WL, mientras que valores altos indican moléculas más periféricas o atípicas.

5.3. Justificación

La excentricidad media es una elección natural para el algoritmo MAPPER porque resume la posición relativa de cada observación dentro del conjunto total sin depender de una representación euclidiana explícita. En este problema resulta adecuada porque el interés principal no es solo identificar grupos aislados, sino ordenar las moléculas según su cercanía promedio al resto del espacio químico y usar esa organización global para construir la cubierta del filtro.

En términos topológicos, esta función induce una organización del espacio que posteriormente será utilizada para construir una cubierta del conjunto de datos.

6. Parámetros de la cubierta

El rango del filtro se divide en intervalos traslapados a partir de los valores observados de excentricidad media. En el subconjunto analizado, el rango del filtro fue:

$$f(x_i) \in [0,4484, 0,9990]$$

Se utilizó una cubierta uniforme sobre este intervalo.

- Número de intervalos: 5
- Porcentaje de traslape: 10 %

Los intervalos obtenidos fueron aproximadamente:

- [0,4484, 0,5695]
- [0,5475, 0,6686]
- [0,6466, 0,7677]

- $[0,7457, 0,8668]$
- $[0,8448, 0,9660]$

Estos parámetros controlan la resolución y la conectividad del grafo resultante. Un número mayor de intervalos produciría una descripción más fina del espacio, mientras que un traslape mayor incrementaría la probabilidad de que aparezcan conexiones entre clusters de intervalos consecutivos.

7. Clustering

7.1. Métrica

Se utiliza la matriz de distancias precomputada como entrada del algoritmo de clustering en las versiones manuales del Mapper. Esto permite que el agrupamiento se base directamente en la similitud estructural inducida por la distancia WL, sin imponer una geometría euclidiana artificial.

7.2. Método

Con el fin de entender mejor el efecto del método de agrupamiento sobre la topología observada, se probaron tres variantes:

- **Mapper manual con clustering aglomerativo:** dentro de cada intervalo se aplicó `AgglomerativeClustering` con distancia precomputada y ligamiento promedio.
- **Mapper manual con DBSCAN:** dentro de cada intervalo se aplicó `DBSCAN` con distancia precomputada.
- **KeplerMapper:** se utilizó la librería `kmapper`, también con `DBSCAN`, pero agrupando sobre la proyección bidimensional obtenida con `UMAP` en lugar de usar directamente la matriz de distancias original como espacio de clustering.

7.3. Parámetros

Versión manual con clustering aglomerativo.

- Número de clusters por intervalo: 3
- Métrica: `precomputed`
- Ligamiento: `average`

Versión manual con DBSCAN.

- $\epsilon = 0,35$
- `min_samples = 3`
- Métrica: `precomputed`

Versión con KeplerMapper.

- Número de cubos: 5
- Traslape: 10 %
- Clusterer: DBSCAN con $\epsilon = 0,5$ y `min_samples = 3`
- Espacio de clustering: proyección UMAP en dos dimensiones

7.4. Justificación

La comparación entre métodos se consideró parte del aprendizaje del ejercicio. La versión aglomerativa resulta útil para construir una descripción global y conectada del espacio de datos, ya que fuerza una partición en cada intervalo. En cambio, DBSCAN es más conservador: solo genera clusters cuando detecta densidad local suficiente y puede dejar regiones sin agrupar. Finalmente, la versión con KeplerMapper permite una visualización interactiva más rica, aunque ya no agrupa directamente en el espacio original de distancias, sino en una proyección bidimensional derivada de UMAP.

En este contexto, los clusters obtenidos dentro de cada intervalo pueden interpretarse como aproximaciones discretas de las componentes conexas de los subconjuntos inducidos por la cubierta del filtro.

8. Construcción del grafo MAPPER

El algoritmo MAPPER se implementó de la siguiente manera:

1. Se evalúa la función filtro sobre cada observación.
2. Se divide el rango del filtro en intervalos traslapados.
3. Se aplica clustering dentro de cada intervalo.
4. Se construye un grafo donde:

- Cada nodo representa un cluster.
- Se conectan nodos si comparten elementos.

En las implementaciones manuales, esta construcción se realizó explícitamente sobre la matriz de distancias WL. Por tanto, la topología obtenida depende de dos decisiones separadas:

- la organización global inducida por el filtro de excentricidad;
- la forma en que cada algoritmo de clustering separa o conecta observaciones dentro de cada intervalo.

Esto es importante porque dos elecciones distintas de clustering pueden producir grafos con conectividad muy diferente aun cuando la cubierta y la función filtro sean las mismas.

8.1. Conexión con el Teorema del Nervio

La construcción del grafo MAPPER puede interpretarse como una aproximación discreta del teorema del nervio. En efecto, la función filtro induce una cubierta del conjunto de datos a través de intervalos traslapados de su rango, y cada uno de estos intervalos define un subconjunto de observaciones mediante su preimagen.

Dentro de cada subconjunto, el uso de clustering permite aproximar sus componentes conexas, de modo que cada cluster puede entenderse como una región local del espacio de datos. El grafo final se construye conectando aquellos clusters que comparten elementos, lo cual refleja la intersección entre subconjuntos de la cubierta.

De esta forma, el grafo MAPPER puede interpretarse como el nervio de una cubierta inducida por la función filtro, proporcionando una representación de la estructura global del espacio de datos a partir de información local.

9. Análisis del resultado

9.1. Estructura global

Los resultados observados fueron los siguientes:

- **Mapper manual + aglomerativo:** 15 nodos, 16 aristas y 1 componente conexa.
- **Mapper manual + DBSCAN:** 10 nodos, 6 aristas y 4 componentes conexas.

- **KeplerMapper + DBSCAN**: 35 nodos y 22 aristas.

Además, en la versión manual con clustering aglomerativo se obtuvo exactamente la misma partición por intervalo:

[3, 3, 3, 3, 3]

es decir, tres clusters por cada uno de los cinco intervalos. En cambio, en la versión manual con DBSCAN se observó una distribución desigual:

[1, 1, 3, 4, 1]

lo que muestra que el algoritmo no fuerza una misma cantidad de agrupamientos en todos los intervalos, sino que responde a la densidad local observada en cada región del filtro.

9.2. Interpretación

La diferencia entre resultados no debe interpretarse como una contradicción, sino como evidencia de que el espacio molecular admite múltiples lecturas según el criterio de agrupamiento.

- En la **versión manual con aglomerativo**, la aparición de una sola componente conexa sugiere una organización global continua del espacio químico: hay transiciones entre intervalos y el algoritmo tiende a conectar regiones que, bajo una partición forzada, quedan enlazadas mediante elementos compartidos.
- En la **versión manual con DBSCAN**, la aparición de cuatro componentes indica una lectura más local y más estricta del espacio de similitud. En este caso, el algoritmo sólo conserva grupos suficientemente densos y deja fuera regiones menos compactas, por lo que la conectividad disminuye.
- En **KeplerMapper**, el número mayor de nodos sugiere una descripción más fina de la estructura. Sin embargo, esta versión no es directamente comparable con las dos manuales, porque el clustering no se hacen el espacio original de distancias, sino sobre la proyección UMAP en dos dimensiones.

Por ello, lo que se observa en los grafos no son necesariamente “familias químicas” en sentido estricto, sino agrupamientos de moléculas que resultan similares bajo la métrica estructural definida por Weisfeiler–Lehman y Tanimoto para conteos.

La interpretación más prudente es la siguiente:

- los **nodos** representan subconjuntos de moléculas con cercanía estructural relativa bajo la distancia elegida;
- las **aristas** representan continuidad entre subconjuntos a través del traslape de la cubierta;
- una **componente conexa grande** sugiere continuidad global o una partición más permisiva;
- varias **componentes desconectadas** sugieren subgrupos locales más compactos o criterios de densidad más estrictos.

Desde una perspectiva topológica, los resultados sugieren que la estructura del espacio químico no es completamente homogénea. La presencia de múltiples componentes en la versión con DBSCAN indica la existencia de regiones localmente densas separadas por zonas de baja conectividad, mientras que la versión aglomerativa sugiere que estas regiones pueden conectarse mediante transiciones graduales cuando se fuerza una partición global.

Esto es consistente con la idea de que el espacio molecular presenta tanto continuidad estructural como zonas de especialización, dependiendo de la resolución a la que se observe.

9.3. Análisis de nodos

En la versión KeplerMapper, algunos nodos destacados por tamaño fueron:

- `cube0_cluster0`: 283 moléculas.
- `cube2_cluster1`: 82 moléculas.
- `cube1_cluster4`: 81 moléculas.
- `cube1_cluster8`: 57 moléculas.
- `cube0_cluster1`: 55 moléculas.

Estos nodos muestran que la distribución de tamaños no es homogénea: existe al menos un grupo muy dominante y varios grupos medianos. Esto sugiere que una parte importante del conjunto está concentrada en regiones relativamente densas del espacio estructural, mientras que otras zonas contienen subconjuntos más especializados o más dispersos.

Aunque no se realizó una caracterización química detallada, el tamaño de los nodos sugiere la existencia de regiones del espacio estructural donde múltiples moléculas comparten patrones comunes, mientras que otros nodos más pequeños podrían corresponder a estructuras menos frecuentes o más especializadas.

10. Identificación de subgrupos

La comparación entre métodos permite identificar dos escalas distintas de subagrupamiento:

- una **escala global**, bien representada por el Mapper manual con clustering aglomerativo, donde el conjunto aparece como una red conectada;
- una **escala local**, mejor representada por la versión manual con DBSCAN, donde emergen varias componentes separadas que pueden interpretarse como subgrupos estructuralmente compactos.

Desde este punto de vista, no es necesario escoger una sola lectura como “la correcta”. Más bien, ambas versiones describen propiedades complementarias del mismo espacio métrico:

- la versión aglomerativa resalta continuidad;
- la versión DBSCAN resalta separación local;
- KeplerMapper aporta un nivel adicional de detalle para exploración visual.

Esta observación es particularmente importante en un problema molecular, donde la noción de cercanía entre observaciones depende de decisiones de representación y métrica, y donde el análisis topológico se usa precisamente para estudiar cómo cambian las conclusiones al modificar la resolución o el criterio de agrupamiento.

11. Conclusiones

12. Conclusiones

El uso de MAPPER en este trabajo permitió entender mejor cómo se organiza el espacio químico definido por la similitud Weisfeiler–Lehman. Más que dar un solo resultado, el algoritmo dejó ver que hay varias formas de “leer” el mismo conjunto de datos dependiendo de las decisiones que se toman en el pipeline.

En particular, usar excentricidad como función filtro ayudó a ordenar las moléculas desde las más centrales hasta las más periféricas. Esto sirvió como base para construir la cubierta y aplicar MAPPER de una forma que tiene sentido con la geometría del problema.

Un punto clave es que la topología que se obtiene cambia bastante según el método de clustering. El clustering aglomerativo tiende a conectar todo y sugiere una estructura más

continua del espacio químico. En cambio, DBSCAN es más estricto y solo agrupa donde hay densidad clara, lo que genera una estructura más fragmentada con varias componentes.

Esto no es una contradicción. Más bien indica que el espacio molecular tiene estructura a distintas escalas. Dependiendo de cómo se mire, se pueden ver tanto conexiones globales como subgrupos más compactos.

También se vio que al usar KeplerMapper, donde el clustering se hace sobre la proyección UMAP, la forma del grafo cambia. Esto refuerza la idea de que el resultado de MAPPER no es único, sino que depende directamente de cómo se construye todo el proceso.

En conjunto, el ejercicio sirvió para entender mejor cómo interactúan la métrica, el filtro, la cubierta y el clustering. No se trata solo de obtener un grafo, sino de ver cómo cambian las conclusiones cuando se modifican estas decisiones.

Como siguiente paso, sería interesante agregar información adicional de las moléculas para poder interpretar mejor los nodos, no solo como grupos estructurales sino también en términos más químicos.